

Erkennung KI-generierter Texte auf Reddit

Eine experimentelle Evaluation von Machine-Learning-Detektoren

Bachelorarbeit

zur Erlangung des akademischen Grades Bachelor of Science (B.Sc.)

Vorgelegt an der
Hochschule München
Fakultät für Informatik und Mathematik

Eingereicht von
Maximilian Raisig
Studiengang: Data Science & Scientific Computing
Matrikelnummer: 59064120

Erstprüfer: Prof. Dr. Anna Kruspe
Betreuer: Prof. Dr. Anna Kruspe
Abgabedatum: 30.09.2026

Sperrvermerk

Die vorliegende Arbeit beinhaltet interne vertrauliche Informationen der Firma XYZ. Die Weitergabe des Inhalts der Arbeit im Gesamten oder in Teilen sowie das Anfertigen von Kopien und Abschriften sind grundsätzlich untersagt. Ausnahmen bedürfen der schriftlichen Zustimmung der Firma.

Kurzfassung

Eine kurze Zusammenfassung des Zwecks, der Methoden, der wichtigsten Ergebnisse und der Schlussfolgerungen der Arbeit.

Danksagung

Ein optionaler Abschnitt, in dem Personen und Organisationen gedankt wird, die die Arbeit unterstützt oder dazu beigetragen haben.

Inhaltsverzeichnis

Abbildungsverzeichnis	VI
Tabellen-, Algorithmen- und Codeverzeichnis	VII
Abkürzungsverzeichnis	VIII
1 Einleitung	1
1.1 Zielsetzung	1
1.2 Relevanz der Erkennung KI-generierter Texte	2
1.3 Abschnitt	2
1.3.1 Unterabschnitt	2
1.4 Forschungsfragen	2
1.5 Kapitelverweise	2
2 Verwandte Arbeiten	3
2.1 Tabellen	3
2.2 Zitate	4
3 Daten und Methodik	5
3.1 Datengrundlage	5
3.2 Abbildungen	5
4 Implementierung	6
4.1 Formeln	6
4.2 Algorithmen	6
4.3 Listen und Aufzählungen	6
4.3.1 Codebeispiele	7
5 Ergebnisse	8
5.1 Diagramme	8
6 Fazit	9
6.1 Gantt-Diagramm	9
Literatur	10
Ehrenwörtliche Erklärung	11
A Anhang	12

A.1	Zusätzliches Material	12
-----	---------------------------------	----

Abbildungsverzeichnis

3.1	DSR-Ansatz mit Relevanz-, Rigorositäts- und Design-Zyklus.	5
5.1	Ausführungszeit nach Größe der Trace-Datei des Frameworks.	8
6.1	Gantt-Diagramm des Projektzeitplans.	9

Tabellenverzeichnis

2.1	Ein- und Ausschlusskriterien für das Literatur-Review.	3
-----	--	---

List of Algorithms

4.1	Blockbasierte Dateiverarbeitung mit Hashing.	6
-----	--	---

List of Code Listings

4.1	Quellcode des Dateiverarbeitungsalgorithmus.	7
-----	--	---

Abkürzungsverzeichnis

DSR	Design Science Research	5
-----	-----------------------------------	---

1 Einleitung

Mit der Veröffentlichung von ChatGPT 3.5 im November 2022 [1] wurde der breiten Öffentlichkeit erstmals der Zugang zu einem niederschweligen KI-Tool zur leichten Informationsbeschaffung ermöglicht, wo dies zuvor über Suchmaschinen erarbeitet werden musste. Schätzungen zufolge erreichte ChatGPT 3.5 innerhalb von zwei Monaten 100 Millionen Nutzer [2]. Die steigende Nutzung und Nachfrage im beruflichen und privaten Alltag führt unweigerlich zu neuen Akteuren im Markt, darunter Google, Meta und Anthropic [3]. Das Resultat ist eine enorme Menge an KI-generierten Inhalten in aller Form, also Text, Video, Bild und Audio. Die Art und Weise, wie digitale Inhalte konsumiert und reproduziert werden, hat sich folglich radikal verändert. Insbesondere Betreiber und Nutzer von sozialen Medien werden mit Inhalten konfrontiert, die durch Bots oder Sprachmodelle erzeugt werden. Daraus resultiert unweigerlich auch eine zunehmende und zunehmend einfachere Verbreitung von Mis- und Desinformation auf diesen Plattformen. Dies wirft gesellschaftliche und ethische Fragen auf, da Sprachmodelle gezielt zur Meinungsbeeinflussung genutzt werden können, indem authentisch und menschlich klingende Inhalte produziert und bewusst verbreitet werden [4]. Soziale Netzwerke wie Reddit basieren qua Definition auf genuin menschlichem Austausch. Dennoch wird geschätzt, dass sich die Zahl der vermutlich von KI generierten Posts auf Reddit zwischen 2024 und 2025 um ca. 13 % erhöht hat [5]. Umso wichtiger ist es also, KI-generierte Inhalte insbesondere in Form von Text auf Reddit zu erkennen.

1.1 Zielsetzung

Das zentrale Ziel dieser Bachelorarbeit ist die Evaluierung verschiedener Machine Learning-Modelle zur Erkennung von KI-generiertem Text. Die dazu verwendeten Daten stammen von der Plattform Reddit aus unterschiedlichen Subreddits. Um einen dazugehörigen KI-generierten Datensatz zu erzeugen, wurde das LLM Llama-3.1-8B-Instruct verwendet. Die Anweisung lautete dabei, einen Post zum jeweiligen Subreddit, auf Basis des Titels und des Inhalts des originalen Posts zu generieren. Auf diesen beiden Datensätzen soll dann untersucht werden, inwieweit bereits trainierte Modelle in der Lage sind, zwischen von Menschen und von KI generierten Texten zu unterscheiden.

1.2 Relevanz der Erkennung KI-generierter Texte

Warum eine zuverlässige Erkennung von KI-generiertem Text relevant ist, begründen [6]: „Recognizing the ‚fingerprint‘ of AI text generation is the foundation for a healthy information ecosystem in the future, but also to prevent model collapse when LLMs are trained increasingly on their own output. However, LLM detection remains a challenge, especially across text domains, but also in the face of potential LLM style obfuscations.”

1.3 Abschnitt

Dies ist ein Beispiel für einen Abschnitt.

1.3.1 Unterabschnitt

Dies ist ein Beispiel für einen Unterabschnitt.

Unterunterabschnitt

Dies ist ein Beispiel für einen Unterunterabschnitt.

1.4 Forschungsfragen

Dies ist ein Beispiel, wie man Forschungsfragen formatiert.

F₁: Ist dies eine Forschungsfrage?

Man kann auf Forschungsfragen wie folgt verweisen: F₁ ist ein Beispiel für eine Forschungsfrage.

1.5 Kapitelverweise

Man kann auf andere Kapitel wie folgt verweisen: Kapitel 6 ist das Abschlusskapitel.

2 Verwandte Arbeiten

Im Laufe der Zeit haben sich parallel zu den generativen Modellen entsprechende Methoden zur Erkennung der erstellten Inhalte entwickelt.

Dabei unterscheiden [7] zwischen statistischen und linguistischen sowie Machine Learning-basierten Ansätzen, Zero-Shot- und modellspezifischen Methoden sowie „Boundary Detection“ und Teiltextanalyse. Statistische und linguistische Ansätze basieren auf der Annahme, dass es strukturelle und stilistische Unterschiede in von künstlicher und menschlicher Intelligenz verfassten Texten gibt. Dazu werden traditionelle statistische Frameworks herangezogen. Darunter fallen z.B. die N-gram-Analyse, „Perplexity“-basierte Methoden und stilometrische Ansätze. Innerhalb der Machine Learning-basierten Methoden stellen die Transformer-basierten Detektoren derzeit den State-of-the-Art in der Anwendung dar. Hervorzuheben sind hier feinabgestimmte Versionen von vortrainierten Modellen wie BERT oder RoBERTa. Zero-Shot- Methoden haben den Vorteil, dass sie nicht auf ein vorheriges Training auf Beispieldaten der generativen Modelle angewiesen sind. Diese umfassen verschiedene Ansätze, u.a. die logarithmische Wahrscheinlichkeitsanalyse, das Binoculars Framework, Wasserzeichen und Perturbationstests. „Boundary Detection“ und Teiltextanalyse tragen dem Umstand Rechnung, dass Mischformen von durch menschliche und künstliche Intelligenz verfassten Texten existieren. Dazu zählen „Sequence Labeling“-Ansätze, „Change Point Detection“-Methoden und die „Multi-Scale“-Analyse von Grenzwerten.

2.1 Tabellen

Tabelle 2.1: Ein- und Ausschlusskriterien für das Literatur-Review.

Einschlusskriterien	Ausschlusskriterien
Englische Sprache	Nicht-englische Sprache
Veröffentlicht 2015–2025	Veröffentlicht vor 2015
Peer-reviewed	Nicht peer-reviewed
Liefert Methode und empirische Ergebnisse	Irrelevantes Fachgebiet oder Off-Topic

Man kann Tabellen erstellen und sie wie folgt referenzieren: Tabelle 2.1 zeigt die Ein- und Ausschlusskriterien für das Literatur-Review.

2.2 Zitate

Quellen können in Klammern wie folgt zitiert werden: Designmuster erleichtern die Wiederverwendung erfolgreicher Entwürfe und Architekturen [8].

Quellen können auch direkt im Text zitiert werden: Gamma u. a. [8] bietet einen umfassenden Überblick über Designmuster.

3 Daten und Methodik

Im Folgenden soll die Datengrundlage und die verwendete Methode genauer erläutert werden.

3.1 Datengrundlage

Grundlage dieser Arbeit sind Posts und Kommentare, die auf dem sozialen Medium Reddit veröffentlicht worden sind und mithilfe von einer API bezogen wurden. Es handelt sich dabei um Datensätze aus ... verschiedenen Subreddits, die im Zeitraum von ... bis ... veröffentlicht wurden.

3.2 Abbildungen




Abbildung 3.1: DSR-Ansatz mit Relevanz-, Rigorositäts- und Design-Zyklus. Adaptiert aus Hevner u. a. [9].

Man kann Abbildungen einfügen und wie folgt darauf verweisen: Abbildung 3.1 zeigt den Design Science Research (DSR)-Ansatz mit Relevanz-, Rigorositäts- und Design-Zyklus.

4 Implementierung

4.1 Formeln

Man kann Formeln wie folgt einfügen: Das Dateiverarbeitungsproblem kann wie folgt modelliert werden. Eine Datei F der Größe S Bytes, aufgeteilt in Blöcke mit maximaler Größe c , ist:

$$F = \langle B_1, B_2, \dots, B_m \rangle, \quad m = \left\lceil \frac{S}{c} \right\rceil$$

4.2 Algorithmen

Man kann Algorithmen mithilfe von Pseudocode wie folgt darstellen:

Algorithm 4.1: Blockbasierte Dateiverarbeitung mit Hashing.

Input: Datei F , Blockgröße c

Output: Datensatz $\langle size, block_count, sha256 \rangle$

```
1:  $h \leftarrow \text{INITSHA256}()$  ▷ Initialisiere Digest.
2:  $size \leftarrow \text{LENGTH}(F)$ 
3:  $block\_count \leftarrow 0$ 

4: for all  $block \in \text{READ}(F, c)$  do
5:    $\text{UPDATE}(h, block)$ 
6:    $block\_count \leftarrow block\_count + 1$ 

7:  $sha256 \leftarrow \text{FINALIZE}(h)$ 
8: return  $\langle size, block\_count, sha256 \rangle$ 
```

Man kann auf Algorithmen wie folgt verweisen: Algorithmus 4.1 beschreibt einen blockbasierten Dateiverarbeitungsalgorithmus.

4.3 Listen und Aufzählungen

Man kann Listen und Aufzählungen wie folgt erstellen:

1. Initialisiere einen SHA-256-Digest und lese die Dateigröße.

2. Lese die Datei in Blöcken von maximal c Bytes.
3. Aktualisiere für jeden Block den Digest und erhöhe den Blockzähler.
4. Finalisiere den Digest, um den Hash zu erhalten.
5. Gib $\langle size, block_count, sha256 \rangle$ zurück.

4.3.1 Codebeispiele

Man kann Quellcode einfügen, zum Beispiel Python-Code, wie folgt:

Listing 4.1: Quellcode des Dateiverarbeitungsalgorithmus.

```
1 import hashlib
2 from pathlib import Path
3
4 def process_file(path: str, chunk_size: int = 1 << 20):
5     p = Path(path)
6     h = hashlib.sha256()
7     with p.open("rb") as f:
8         while True:
9             b = f.read(chunk_size)
10            if not b:
11                break
12            h.update(b)
13     return {
14         "file": p.name,
15         "size_bytes": p.stat().st_size,
16         "sha256": h.hexdigest()
17     }
18
19 if __name__ == "__main__":
20     print(process_file("example.dat"))
```

5 Ergebnisse

5.1 Diagramme

Dies ist ein Diagramm, das mit Python (Jupyter Notebook) erstellt wurde, um den Stil des Dokuments beizubehalten.



Abbildung 5.1: Ausführungszeit nach Größe der Trace-Datei des Frameworks.

6 Fazit

6.1 Gantt-Diagramm

Dies ist ein Gantt-Diagramm, das mit draw.io erstellt wurde, um den Stil des Dokuments beizubehalten.

Activity	March	April	May	June	July	August
Define Research Scope						
Conduct Literature Review						
Implement Solution						
Evaluation and Refinement						
Thesis Writing						
Buffer						

Abbildung 6.1: Gantt-Diagramm des Projektzeitplans.

Literatur

- [1] OpenAI, *Introducing Chatgpt*, Nov. 2022. besucht am 16. Feb. 2026. Adresse: <https://openai.com/index/chatgpt/>
- [2] K. Hu, „ChatGPT sets record for fastest-growing user base - analyst note,“ *Reuters*, 2. Feb. 2023. besucht am 23. Feb. 2026. Adresse: <https://www.theguardian.com/world/2017/mar/12/netherlands-will-pay-the-price-for-blocking-turkish-visit-erdogan>
- [3] N. L. Le und M.-H. Abel, *How Well Do LLMs Predict Prerequisite Skills? Zero-Shot Comparison to Expert-Defined Concepts*, 2025. arXiv: 2507.18479 [cs.IR]. Adresse: <https://arxiv.org/abs/2507.18479>
- [4] M. Coeckelbergh, „LLMs, Truth, and Democracy: An Overview of Risks,“ *Science and Engineering Ethics*, Jg. 31, 4 2025. DOI: <https://doi.org/10.1007/s11948-025-00529-0> Adresse: <https://link.springer.com/article/10.1007/s11948-025-00529-0>
- [5] M. Lambert, „15% of Reddit Posts are Likely AI-generated in 2025,“ Dez. 2025. besucht am 23. Feb. 2026. Adresse: <https://originality.ai/blog/ai-reddit-posts-study>
- [6] J. Bevendorff u. a., *Overview of PAN 2026: Voight-Kampff Generative AI Detection, Text Watermarking, Multi-Author Writing Style Analysis, Generative Plagiarism Detection, and Reasoning Trajectory Detection*, 2026. arXiv: 2602.09147 [cs.CL]. Adresse: <https://arxiv.org/abs/2602.09147>
- [7] T. Kehkashan u. a., „AI-generated text detection: A comprehensive review of methods, datasets, and applications,“ *Computer Science Review*, Jg. 58, S. 100 793, 2025, ISSN: 1574-0137. DOI: <https://doi.org/10.1016/j.cosrev.2025.100793> Adresse: <https://www.sciencedirect.com/science/article/pii/S1574013725000693>
- [8] E. Gamma, R. Helm, R. Johnson und J. M. Vlissides, *Design Patterns: Elements of Reusable Object-Oriented Software*, 1. Aufl. Addison-Wesley Professional, 1994, ISBN: 0201633612. Adresse: http://www.amazon.com/Design-Patterns-Elements-Reusable-Object-Oriented/dp/0201633612/ref=ntt_at_ep_dpi_1
- [9] A. Hevner u. a., „Design Science in Information Systems Research,“ *Management Information Systems Quarterly*, Jg. 28, S. 75–, März 2004.

Ehrenwörtliche Erklärung

Hiermit erkläre ich, dass ich die vorliegende Masterarbeit selbständig verfasst, noch nicht anderweitig für Prüfungszwecke vorgelegt, keine anderen als die angegebenen Quellen oder Hilfsmittel benützt sowie wörtliche und sinngemäße Zitate als solche gekennzeichnet habe.

München, 01.01.2025

Ort, Datum

Max Mustermann

Unterschrift

A Anhang

A.1 Zusätzliches Material